

MPUM miniprojekt 1 - raport

Szymon Trofimiec

8 kwietnia 2026

1 Preliminaria

Macierz planowania skalujemy zgodnie ze wzorem $\hat{X} = \frac{X - \mu}{\sigma}$, gdzie μ i σ oznaczają odpowiednio średnią i odchylenie standardowe zbioru treningowego. Przed uruchomieniem algorytmu GD wektor parametrów θ inicjalizujemy zerami.

2 Rozwiązanie analityczne

Najpierw porównałem rozwiązanie analityczne bez regularyzacji dla różnych funkcji bazowych na zbiorze walidacyjnym.

Base function	MSE
1st degree polynomial	53293.0762
2nd degree polynomial	13245.4842
3rd degree polynomial	12939.7304
4th degree polynomial	7366.8780
5th degree polynomial	3181.0212
6th degree polynomial	1570.4442
7th degree polynomial	1559.6032
8th degree polynomial	1476.8118
linear combination of x_1, x_2 and x_3, x_4	53212.6562
exponential	17203.3932
sigmoid	10824.1252
square root	16191.2027

Funkcja sigmoid, pierwiastek oraz funkcja wykładnicza wyraźnie lepiej opisują dane niż regresja liniowa bez funkcji bazowej (tj. wielomian pierwszego stopnia). Zauważmy również, że MSE znacząco maleje wraz ze wzrostem stopnia wielomianu. Między pierwszym a szóstym stopniem wielomianu MSE zmniejsza się około 350 razy. Dla większych stopni zmiana jest wolniejsza, co sugeruje, że wielomian szóstego stopnia może być wystarczający do opisu tych danych.

Liniowa kombinacja dwóch cech nie dała satysfakcjonujących rezultatów, jednak wielomiany wyższych stopni z dodatkowymi kombinacjami cech mogłyby dawać lepsze wyniki.


Następnie przeprowadziłem analizę rozwiązania analitycznego z regularyzacją L_2 dla wybranych funkcji bazowych oraz próbowałem dobrać optymalne parametry regularyzacji:

	x	exp	sqrt	sigmoid	x^6
$\lambda = 0$	53293.0762	17203.3932	16191.2027	10824.1252	1570.4442
$\lambda = 0.001$	53297.4808	17226.2801	16199.7495	10942.4288	72313.9730
$\lambda = 0.01$	53337.1224	17432.2622	16276.6706	12007.1084	576775.4500
$\lambda = 0.1$	53733.5303	19492.0156	17045.8434	22648.7085	1779235.0738
$\lambda = 1$	57696.8025	40082.8492	24733.8311	128548.6124	2467184.1943

W tym przypadku regularyzacja nie poprawiła wyników żadnego z modeli. Co więcej, można zauważyć, że dla funkcji bazowych, które szybko rosną, regularyzacja działa bardzo niekorzystnie.

3 Metody gradientowe


Najpierw przetestowałem różne funkcje bazowe dla regresji bez regularyzacji:



W tym eksperymencie ustaliłem współczynnik uczenia na 0,001 oraz rozmiar batcha na 16. Wyniki są analogiczne do tych w rozwiązaniu analitycznym: funkcja wykładnicza, sigmoid oraz wielomiany wyższych stopni działają znacznie lepiej niż wielomian pierwszego stopnia.

Można również zauważyć, że wielomian 8. stopnia jest niestabilny w trakcie uczenia konieczne było zmniejszenie współczynnika nauczania, ponieważ gradient eksplodował.


Dalej rozważam jedynie funkcję wykładniczą, sigmoid oraz wielomian stopnia 6. Najpierw sprawdziłem wpływ regularyzacji na te modele. Poniżej przedstawiono wykres tylko dla wielomianu, a pozostałe można obejrzeć w kodzie.



Dla wszystkich modeli regularyzacja L_1 okazała się mało istotna, natomiast L_2 często pogarszała wynik. Następnie dobrałem odpowiednie hiperparametry: szczegóły ich wyznaczania znajdują się w kodzie (wykresy byłyby nieczytelne w raporcie). Ostateczne wartości przedstawiam poniżej:

Funkcja	Learning Rate	Batch Size
sigmoid	0.01	16
exponential	0.001	16
x^6	0.0001	1

4 Porównanie modeli



Modele trenowane metodą gradientową były uruchamiane przez 100 epok bez regularyzacji, z malejącą szybkością uczenia.

Dla porównania pomarańczową linią zaznaczono klasyczną regresję liniową. Każdy z analizowanych modeli istotnie poprawia wartość MSE, przy czym funkcja sigmoid oraz wielomian 6. stopnia osiągają nieco lepsze wyniki.

Niestety, model oparty na wielomianie 6. stopnia bywał niestabilny i niektórych przypadkach dochodziło do przepełnień. Z tego powodu zdecydowałem się nie uwzględniać go w dalszej analizie.

5 Podsumowanie

W miniprojekcie zbadałem rozwiązanie analityczne i metody gradientowe regresji liniowej. W podejściu analitycznym najlepiej sprawdzały się wielomiany wysokiego stopnia, jednak w metodach gradientowych okazały się one niepraktyczne. Z kolei funkcje zawierające elementy wykładnicze były znacznie bardziej stabilne w procesie uczenia.

Nawet bez szczegółowej analizy danych można zauważyć, że do ich opisu potrzebna jest funkcja posiadająca kilka ekstremów. Można by wywnioskować, że sumy funkcji Gaussowskich lub inne funkcje o podobnym charakterze mogłyby być tu szczególnie skuteczne.