

MPUM Miniprojekt 2 - Raport

Szymon Trofimiec


16 kwietnia 2026

1 Regresja Logistyczna

Jako parametry GD dla regresji logistycznej wybrałem :

- **learning rate = 0.01**
- **batch size = 16** - w połączeniu z współczynnikiem uczenia gwarantują stabilność uczenia
- **learning rate decay = 0**


Wektor współczynników ϕ inicjalizuje zerami. a jako funkcje straty używam cross entropy. Do tego używam regularyzacji l2 z parametrem 0.1.



Wykres jest średnią 10 uruchomień programu. Już po pierwszych kilku epokach poprawność wynosi około 96%, a po 200 kończy gdzieś w okolicach 96.5 %

2 Naiwny klasyfikator bayesowski i porównanie modeli

Po zastosowaniu naiwnego klasyfikatora bayesowskiego z wygładzeniem na frakcjach zbioru treningowo wypada on na tle regresji logistycznej następująco:



Po uruchomieniu na pełnym zbiorze treningowym klasyfikator bayesowski osiąga poprawność $\approx 97\%$, co jest odrobinę lepszym wynikiem niż regresja logistyczna. Można również zauważyć, że poprawność klasyfikatora stabilizuje się już dla niewielkiej frakcji zbioru treningowego. Za to dla regresji liniowej widać, że poprawność nie stabilizuje się do samego końca, więc istnieje szansa, że dla większej ilości danych poprawność wzrosłaby jeszcze bardziej.

3 Wnioski

W artykule *On Discriminative vs. Generative Classifiers: A comparison of logistic regression and naive Bayes* Andrew Nga i Michaela Jordana autorzy dotarli do wniosków, że choć regresja logistyczna ma potencjał na osiągnięcie lepszych wyników, to naiwny klasyfikator bayesowski szybciej osiąga swoją najlepszą wydajność dla dużo mniejszych zbiorów treningowych. Cechy są losowane z przestrzeni $[10]^9$, a według wyników pracy naiwny klasyfikator bayesowski powinien osiągać maksymalną skuteczność dla zbioru treningowego rozmiaru $O(\log(\text{rozmiar przestrzeni})) \approx 20$, a regresja logistyczna dla rozmiaru $O(\text{rozmiar przestrzeni})$. Widać, że dla frakcji 0.125 (czyli zbioru o rozmiarze 60) naiwny klasyfikator bayesowski osiąga już prawie maksymalną wydajność, co potwierdza wyniki z pracy. Z drugiej strony widać, że nawet dla całego zbioru treningowego regresja logistyczna widocznie nie osiąga maksymalnej poprawności, co jest spowodowane niewystarczającym rozmiarem danych - według autorów potrzebowalibyśmy około 10^9 instancji zbioru treningowego aby zauważyć, że regresja logistyczna się stabilizuje.